

Def. Eine Editoperation ist ein Paar  $(\alpha, \beta)$  mit  $\alpha, \beta \in (A^+ \cup \{\epsilon\})$  und  $\alpha \neq \epsilon$  oder  $\beta \neq \epsilon$  21.10  
(1)

Schreibweise  $(\alpha, \beta)$

$\alpha \rightarrow \beta$

$\Rightarrow \epsilon \rightarrow \epsilon$  ist keine Eop.

• Drei Möglichkeiten für  $\alpha \rightarrow \beta$

-  $\alpha \in A^+, \beta = \epsilon$

$\Rightarrow a \rightarrow \epsilon$  für  $a \in A$  Löschen von  $a$

-  $\alpha = \epsilon, \beta \in A^+$

$\Rightarrow \epsilon \rightarrow b$  für ein  $b \in A$   
Einfügen von  $b$

-  $\alpha, \beta \in A^+$

$\Rightarrow a \rightarrow b$  für  $a, b \in A$

Ersetzung von  $a$  durch  $b$

Löschen oder Einfügen = indelet.

Def Ein Alignment  $A$  von Sequenzen  $u$  und  $v$  ist eine Folge  $(\alpha_1 \rightarrow \beta_1, \alpha_2 \rightarrow \beta_2, \dots, \alpha_n \rightarrow \beta_n)$  mit

$$\alpha_1 \alpha_2 \dots \alpha_n = u$$

$$\beta_1 \beta_2 \dots \beta_n = v$$

Beweisatz:

21.10.

(2)

Seien  $u$  und  $v$  Folgen der  
Längen  $m$  bzw.  $n$ .

Sei  $A$  ein Klippunkt von  $u$  und  $v$

Dann gilt  $m + n \geq |A| = h \geq \max\{m, n\}$

Die Anzahl der Klippunkte von  
zwei festen aber beliebig Folgen  
der Längen  $m$  und  $n$ .

• 1.  $m=0, n=0$

• Sei  $A$  ein Klippunkt von  $u$  und  $v$   
der Länge  $h$

$$m+n \geq h \geq \max\{m, n\}$$

$$0+0 \geq h \geq \max\{0, 0\} = 0$$

$$\Rightarrow h=0$$

$A$  ist das leere Klippunkt, ~~also~~

1

2.  $m=0$  und  $n>0$

$$m+n = 0+n = n \geq h \geq \max\{m, n\} = n$$

$A$  hat die Länge  $h=n$

1

3.  $m>0$  und  $n=0$

1



$$m > 0, n > 0$$

21.10.

③

Jeder Alignment von  $u$  und  $v$  enthält  
hat mindestens eine Editoperation.  
Betrachte die letzte Editop. in dem  
Alignment von  $u$  und  $v$  und setze  
die Menge aller Alignments in  
drei Teilmengen

- betrachte die Menge der Alignments  
von  $u$  und  $v$ , die mit Löschung  
enden

$\Rightarrow$  alle Edit. enthalten die  
Löschop.  $u[m] \rightarrow \epsilon$

$\Rightarrow$  diese Menge ist genauso groß  
wie die Menge der Alignments  
die  $u[1..m-1]$  und  $v$   
alignieren

Aligns( $m-1, n$ )

- betrachte Menge der Alignments von  
 $u$  und  $v$ , die mit Einfügung enden  
Einfügung  $\epsilon \rightarrow v[n]$

$\Rightarrow$  Menge ist genauso groß wie Menge  
der Alignments von  $u$  und  $v[1..n-1]$   
Aligns( $m, n-1$ )



$$\text{Aligns}(m, n) = 1$$

21.10 (4)  
für  $m=0$  oder  
 $n=0$

$$\text{Aligns}(m, n) =$$

für  $m > 0$  und  
 $n > 0$

$$\begin{aligned} & \text{Aligns}(m-1, n) + \\ & \text{Aligns}(m, n-1) + \\ & \text{Aligns}(m-1, n-1) \end{aligned}$$

3. Fall

$$\Rightarrow \text{Aligns}(m-1, n-1)$$

$$\text{Aligns}(n, n) \approx (1 + \sqrt{2})^{2n+1} \cdot \sqrt{n}$$

$$n = 1000 \Rightarrow (1 + \sqrt{2})^{2001} \cdot \sqrt{1000} = 10^{767,4}$$

$$\begin{pmatrix} a & - \\ - & b \end{pmatrix} \quad \begin{pmatrix} - & a \\ b & - \end{pmatrix}$$

Def Eine Subsequenz von  $u$  und  $v$  ist eine Folge von Index Paaren

$$\begin{array}{l} \text{mit} \\ (i_1, j_1), (i_2, j_2), \dots, (i_r, j_r) \end{array} \left| \begin{array}{l} (i_1, j_1) \\ u(i_1) \\ \downarrow \\ v(j_1) \end{array} \right.$$

$$\begin{array}{l} 1 \leq i_1 < i_2 < \dots < i_r \leq m \\ 1 \leq j_1 < j_2 < \dots < j_r \leq n \end{array}$$

Beobachtung der  $\text{Subseqs}(m, n)$  die Anzahl der Subsequenzen von  $m$  Zeichenfolgen der Länge  $m$  und  $n$ . Es gilt:

$$\text{Subseqs}(m, n) = \sum_{r=0}^{\min(m, n)} \binom{m}{r} \cdot \binom{n}{r}$$

Approx

$$\text{Subseqs}(m, n) \approx 2^{2n} \cdot (4 \cdot \sqrt{n\pi})^{-1}$$

$n=1000$

$$\text{Subseqs}(1000, 1000) \approx 10^{600}$$

$$\binom{m}{r} = \frac{m!}{r! (m-r)!} \text{ für } m \geq r$$

Bewertungsmodell für Alignment

Def Eine Kostenfunktion  $\delta$  weist einer Editop.  $\alpha \rightarrow \beta$ ,  $\alpha \neq \beta$  positive reelle Kosten  $\delta(\alpha \rightarrow \beta)$  zu

Kosten von  $\alpha \rightarrow \beta$

Die Kosten von  $\alpha \rightarrow \alpha$  sind  $\delta(\alpha \rightarrow \alpha) = 0$

Einheitskosten:

$$\delta(\alpha \rightarrow \beta) = \begin{cases} 0 & , \alpha = \beta \\ 1 & , \text{sonst} \end{cases}$$



Sei  $A = (\alpha_1 \rightarrow \beta_1, \dots, \alpha_L \rightarrow \beta_L)$  <sup>2.1.10.</sup> ⑥  
ein Alignment. Sei  $\delta$  eine Kostenfunktion.  
Die Kosten  $\delta(A)$  von  $A$  sind def.  
durch

$$\delta(A) = \sum_{i=1}^L \delta(\alpha_i \rightarrow \beta_i)$$

Def. Die Edit Distanz von  $u$  und  $v$ ,  
bezeichnet durch  $\text{edist}_\delta(u, v)$  ist

$$\text{edist}_\delta(u, v) = \min \{ \delta(A) \mid A \text{ ist ein Alignment von } u \text{ und } v \} \quad (*)$$

$A$  ist ein optimales Alignment von  $u$  und  $v$  falls  $\delta(A) = \text{edist}_\delta(u, v)$ .

Problemdef..

ED-Problem :

- berechne  $\text{edist}_\delta(u, v)$
- bestimme die opt. Alignments